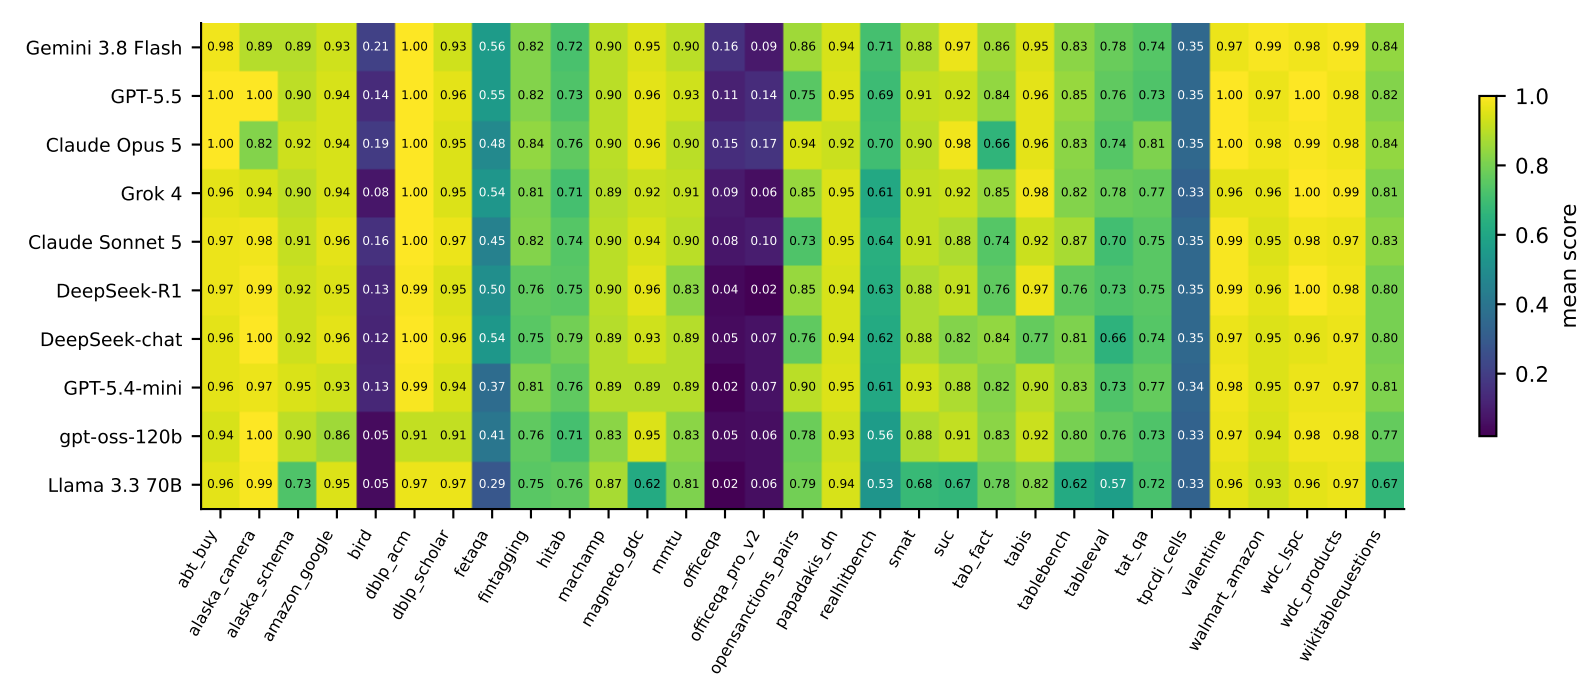
Gemini 3.8 Flash 0.98 0.89 0.89 0.93 0.21 1.00 0.93 0.56 0.82 0.72 0.90 0.95 0.90 0.16 0.09 0.86 0.94 0.71 0.88 0.97 0.86 0.95 0.83 0.78 0.74 0.35 0.97 0.99 0.98 0.99 0.84
GPT-5.5 1.00 1.00 0.90 0.94 0.14 1.00 0.96 0.55 0.82 0.73 0.90 0.96 0.93 0.11 0.14 0.75 0.95 0.69 0.91 0.92 0.84 0.96 0.85 0.76 0.73 0.35 1.00 0.97 1.00 0.98 0.82
Claude Opus 5 1.00 0.82 0.92 0.94 0.19 1.00 0.95 0.48 0.84 0.76 0.90 0.96 0.90 0.15 0.17 0.94 0.92 0.70 0.90 0.98 0.66 0.96 0.83 0.74 0.81 0.35 1.00 0.98 0.99 0.98 0.84
Grok 4 0.96 0.94 0.90 0.94 0.08 1.00 0.95 0.54 0.81 0.71 0.89 0.92 0.91 0.09 0.06 0.85 0.95 0.61 0.91 0.92 0.85 0.98 0.82 0.78 0.77 0.33 0.96 0.96 1.00 0.99 0.81
Claude Sonnet 5 0.97 0.98 0.91 0.96 0.16 1.00 0.97 0.45 0.82 0.74 0.90 0.94 0.90 0.08 0.10 0.73 0.95 0.64 0.91 0.88 0.74 0.92 0.87 0.70 0.75 0.35 0.99 0.95 0.98 0.97 0.83
DeepSeek-R1 0.97 0.99 0.92 0.95 0.13 0.99 0.95 0.50 0.76 0.75 0.90 0.96 0.83 0.04 0.02 0.85 0.94 0.63 0.88 0.91 0.76 0.97 0.76 0.73 0.75 0.35 0.99 0.96 1.00 0.98 0.80
DeepSeek-chat 0.96 1.00 0.92 0.96 0.12 1.00 0.96 0.54 0.75 0.79 0.89 0.93 0.89 0.05 0.07 0.76 0.94 0.62 0.88 0.82 0.84 0.77 0.81 0.66 0.74 0.35 0.97 0.95 0.96 0.97 0.80
GPT-5.4-mini 0.96 0.97 0.95 0.93 0.13 0.99 0.94 0.37 0.81 0.76 0.89 0.89 0.89 0.02 0.07 0.90 0.95 0.61 0.93 0.88 0.82 0.90 0.83 0.73 0.77 0.34 0.98 0.95 0.97 0.97 0.81
gpt-oss-120b 0.94 1.00 0.90 0.86 0.05 0.91 0.91 0.41 0.76 0.71 0.83 0.95 0.83 0.05 0.06 0.78 0.93 0.56 0.88 0.91 0.83 0.92 0.80 0.76 0.73 0.33 0.97 0.94 0.98 0.98 0.77
Llama 3.3 70B 0.96 0.99 0.73 0.95 0.05 0.97 0.97 0.29 0.75 0.76 0.87 0.62 0.81 0.02 0.06 0.79 0.94 0.53 0.68 0.67 0.78 0.82 0.62 0.57 0.72 0.33 0.96 0.93 0.96 0.97 0.67
abt_buy
alaska_camera
alaska_schema
amazon_google
bird
dblp_acm
dblp_scholar
fetaqa
fintagging
hitab
machamp
magneto_gdc
mmtu
officeqa
officeqa_pro_v2
opensanctions_pairs
papadakis_dn
reallifebench
smat
suc
tab_fact
tabis
tablebench
tableeval
tat_qa
tpcdi_cells
valentine
walmart_amazon
wdc_lspc
wdc_products
wikitablequestions
1.0
0.8
0.6
0.4
0.2
mean score